

ANO
2026



UNINTER

**CADERNO DE RESPOSTAS DA
ATIVIDADE PRÁTICA DE:**

NLP

**ALUNO: ALFONSO ALBERTO SLOVINSKI
CANFILD - RU 351946**



Prática 01 – Criação de modelo de classificação supervisionado para análise de Fake News.

Questão 01 – Apresente aqui o código referente ao modelo gerado e a nuvem de palavras que foram usadas para identificar textos VERDADEIROS (Estes códigos devem estar completos, incluindo as importações, os processamentos, os treinamentos e a geração da nuvem de palavras específica solicitada.)

ENUNCIADO: Veja o Roteiro da Atividade Prática para mais detalhes.

I. Apresentação do Código (não esquecer do identificador pessoal):

```
# QUESTÃO 01 - Nuvem de palavras dos termos usados para textos REAL
# RU_351946_q1 = 351946

feature_names_351946 = np.array(vetorizador_351946.get_feature_names_out())

# Máscara booleana das linhas de TREINO rotuladas como REAL ('true')
mascara_real_351946 = (y_train.values == 'true')

# Soma dos pesos TF-IDF de cada termo, considerando apenas os textos REAL usados no treino
soma_tfidf_real_351946 = np.asarray(X_train[mascara_real_351946].sum(axis=0)).flatten()

dic_real_351946 = {
    palavra: freq
    for palavra, freq in zip(feature_names_351946, soma_tfidf_real_351946)
    if freq > 0
}

qtd_termos_real_351946 = len(dic_real_351946)
print(f"Quantidade de palavras/bigramas/trigramas usados dos textos REAL: {qtd_termos_real_351946}")
print(f"Acurácia do modelo: {acuracia_351946*100:.2f}%")

# Insere o identificador pessoal (RU) como um termo de destaque na nuvem
dic_real_351946['RU_351946'] = max(dic_real_351946.values()) * 1.2

nuvem_real_351946, _ = gerar_nuvem_palavras(
    dicionario_tokens_e_frequencia=dic_real_351946,
    arquivo_mascara='thumbs_up_mask.png'
)
```

Figura 1: Código que pega os termos mais fortes pra classe REAL (com base no TF-IDF) e gera a nuvem de palavras. RU 351946 identificado nas variáveis.

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):



Figura 2: Nuvem de palavras dos textos REAL, em verde. Palavras como "govern", "presid", "federal" e "tribun" aparecem em destaque, mostrando um tom mais formal e institucional, como esperado de notícias verdadeiras. RU 351946 na imagem.

III. Responda à pergunta: Quantas palavras, bigramas e trigramas foram usados dos textos rotulados como REAL para a criação de seu modelo e qual a acurácia?

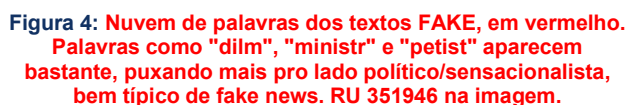
Resposta: Foram usados 5.953 termos (entre palavras, bigramas e trigramas) dos textos rotulados como REAL, com base no TF-IDF. A acurácia do modelo foi de 90,83%.

Questão 02 – Apresente aqui o código referente ao modelo gerado e a nuvem de palavras que foram usadas para identificar textos FALSOS. (Estes códigos devem estar completos, incluindo as importações, os processamentos, os treinamentos e a geração da nuvem de palavras específica solicitada.)

I. Apresentação do Código (não esquecer do identificador pessoal):

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

Figura 3: Código que pega os termos mais fortes pra classe FAKE (com base no TF-IDF) e gera a nuvem de palavras. RU 351946 identificado nas variáveis.



III.	Responda à pergunta: Quantas palavras, bigramas e trigramas foram usados dos textos rotulados como FAKE para a criação de seu modelo, quais foram as técnicas usadas em seu pré-processamento e qual tipo de modelo foi escolhido para este classificador?
------	--

2

**LINK do seu projeto, se existir (google colab de acesso aberto
ou repositório github público):**

https://github.com/AlfonsoCanfild/NLP_351946